

基于深度学习的牛津宠物细粒度分类实验报告

姓名: xuqiang

学号: W125301182

GitHub: <https://github.com/xuqiang/pet-classifier>

1. 任务背景与实验设置

1.1 任务背景

细粒度图像分类 (Fine-Grained Image Classification) 是计算机视觉中的重要任务，目标是区分同一大类下的不同子类别（如不同品种的猫狗）。与普通图像分类相比，细粒度分类的类间差异极小，往往只体现在局部细节（如毛色纹理、头部形状、耳朵大小）上，对模型的特征提取能力提出了更高要求。

本项目以 Oxford-IIIT Pet 数据集为研究对象，基于 ResNet-18 预训练模型构建细粒度分类基线，并通过两组单变量消融实验验证正则化方法对细粒度分类的效果。

1.2 数据集概况

Oxford-IIIT Pet 数据集包含 37 个猫狗品种（25 种狗 + 12 种猫），共约 7349 张图片。每个品种约 200 张图片，类别分布相对均衡。

数据划分：采用分层抽样 (Stratified Split) 按 70% / 15% / 15% 划分为训练集、验证集和测试集，确保每个品种在三个子集中的比例一致。划分后训练集约 5144 张，验证集约 1102 张，测试集约 1103 张。

数据预处理：

- 训练集: $\text{Resize}(256) \rightarrow \text{RandomCrop}(224) \rightarrow \text{RandomHorizontalFlip} \rightarrow \text{ToTensor} \rightarrow \text{Normalize}$ (ImageNet 均值方差)
- 验证/测试集: $\text{Resize}(256) \rightarrow \text{CenterCrop}(224) \rightarrow \text{ToTensor} \rightarrow \text{Normalize}$

验证集和测试集不使用任何随机增强，以保证评估的确定性和可复现性。

1.3 实验环境与超参数

- 硬件环境: NVIDIA Tesla T4 GPU (Kaggle Notebook)
- 框架版本: PyTorch 2.10.0 + torchvision
- 模型架构: ResNet-18 (ImageNet 预训练)，替换最后一层全连接层输出为 37 类
- 优化器: AdamW, 学习率 $1e-4$
- 损失函数: CrossEntropyLoss (Baseline)

- **Batch Size**: 32
- **训练轮数**: 15 Epochs
- **随机种子**: 42 (保证可复现)

2. 实验结果与消融分析

2.1 实验对比表格

本项目完成了两组单变量消融实验，分别验证 Label Smoothing 和 MixUp 两种正则化方法对细粒度分类的影响。所有实验均保持模型架构、优化器、学习率、Batch Size、训练轮数、随机种子等条件完全一致，仅改变单一变量。

实验配置	Top-1 Acc (%)	Top-5 Acc (%)	Macro-F1	训练耗时
1. Baseline (ResNet-18 + 基础增强)	92.20	99.18	0.9216	~5min
2. + Label Smoothing ($\epsilon=0.1$)	92.84	99.18	0.9287	~5min
3. + MixUp ($\alpha=0.2$)	91.84	99.09	0.9177	~6min

2.2 消融实验分析

Label Smoothing 实验: 将标准 CrossEntropyLoss 的 one-hot 标签替换为软化标签 (正确类目标概率 0.9, 其余 36 类平分 0.1)。实验结果表明, Label Smoothing 使 Top-1 准确率提升了 0.64%, Macro-F1 提升了 0.007, 验证集最佳准确率从 91.21% 提升到 92.75%。这说明在细粒度分类任务中, Label Smoothing 通过防止模型过度自信、软化类别边界, 有效缓解了过拟合, 提升了模型的泛化能力。

MixUp 实验: 在训练阶段将两张图片按 Beta(0.2, 0.2) 分布采样的比例进行像素混合, 标签也按相同比例混合。实验结果显示, MixUp 的验证集最佳准确率 (91.84%) 略高于 Baseline (91.21%), 但测试集 Top-1 (91.84%) 略低于 Baseline (92.20%)。这说明 MixUp 在本数据集上的效果不稳定, 可能原因包括: (1) $\alpha=0.2$ 的超参数未经过充分调优; (2) 细粒度分类中不同品种的图像混合可能引入噪声, 干扰局部细节特征的学习; (3) MixUp 更适合大规模数据集, 在本数据集 (约 7000 张) 上增益有限。

2.3 训练曲线分析

从训练曲线可以观察到:

- Baseline 的训练准确率在后期达到 99% 以上, 而验证准确率在 90%~91% 之间波动, 训练 Loss 持续下降但验证 Loss 出现回升, 存在明显的过拟合现象。
- Label Smoothing 的训练 Loss 绝对值较高 (因标签被软化, 理论下界不为 0), 但验证集准确率更稳定且最终更高, 说明过拟合得到了有效缓解。

- MixUp 的训练准确率较低（约 50%~55%），这是因为混合图像的标签是软标签，难以完全匹配主要标签，属于正常现象；其验证准确率波动较大，反映了该方法的不稳定性。

3. 错误案例分析与 Grad-CAM 可视化

3.1 混淆矩阵分析

通过绘制 37 类的混淆矩阵热力图，可以发现模型的错误主要集中在外观高度相似的品种之间，没有出现“猫被预测成狗”这类离谱错误，说明模型学到了有效的类别特征。

最易混淆的品种对包括：

- American Pit Bull Terrier ↔ American Bulldog：两种斗牛犬，头部形状、肌肉体型、短毛特征高度相似
- Staffordshire Bull Terrier ↔ American Pit Bull Terrier：三种斗牛犬之间互相混淆
- Ragdoll ↔ Birman：两种长毛猫，均有蓝色眼睛和浅色毛发，毛色花纹接近
- Chihuahua ↔ Miniature Pinscher：两种小型短毛犬，体型和耳朵形状相似
- Russian Blue ↔ British Shorthair：两种短毛猫，毛色和体型有重叠

这些错误均属于“合理错误”，即人类专家也可能混淆的品种对，说明模型的错误模式符合人类认知。

3.2 Grad-CAM 热力图分析

Grad-CAM（Gradient-weighted Class Activation Mapping）通过可视化模型最后一层卷积层的梯度加权特征图，揭示模型在做预测时“关注”图像的哪些区域。

本项目选取了一张预测正确和一张预测错误的图片进行 Grad-CAM 可视化：

预测正确的样本（狗）：热力图的高响应区域（红色）集中在狗的头部和脸部，包括耳朵、眼睛和口鼻区域。这符合犬类品种识别的关键特征区域——狗的品种主要通过头部形状、耳朵形态、口鼻比例等面部特征区分，说明模型关注了正确的判别区域。

预测错误的样本（暹罗猫被预测为孟买猫）：热力图的高响应区域集中在猫的脸部和眼睛区域。暹罗猫和孟买猫均具有深色脸部和蓝色眼睛，外观高度相似，模型关注的区域是合理的，但由于这两个品种的局部特征过于接近，模型未能做出正确区分。这进一步验证了混淆矩阵的分析结论：错误主要来源于外观相似品种之间的细微差异难以区分。

Grad-CAM 分析表明，模型的注意力机制是合理的，没有出现关注背景或无关区域的情况，模型的可解释性良好。

4. AI 辅助编程声明与 Bug 复盘

4.1 AI 辅助编程声明

本项目在以下环节使用了 AI 编程工具（豆包）辅助开发：

1. **数据加载模块**：辅助编写 Oxford-IIIT Pet 数据集的分层抽样划分逻辑和 Transform 封装
2. **Grad-CAM 可视化**：辅助实现 hook 注册、梯度加权特征图生成和热力图叠加显示
3. **模块化重构**：辅助将 Notebook 代码整理为规范的 Python 工程目录结构
4. **训练循环编写**：辅助实现 MixUp 的数据混合逻辑和损失函数加权计算

所有 AI 生成的代码均经过人工审查、调试和验证，确保逻辑正确、结果可复现。

4.2 Bug 复盘

在项目开发过程中，遇到并修复了以下典型 Bug：

Bug 1: AttributeError: 'list' object has no attribute 'numpy'

- **现象**：访问 `dataset._labels.numpy()` 时报错
- **原因**：当前 torchvision 版本中 OxfordIIITPet 的 `_labels` 属性是 Python list 而非 torch.Tensor
- **修复**：改为 `np.array(dataset._labels)`

Bug 2: ValueError: Unknown value 'all' for argument split

- **现象**：设置 `split="all"` 加载完整数据集时报错
- **原因**：当前 torchvision 版本的 OxfordIIITPet 仅支持 `'trainval'` 和 `'test'` 两种 split，不支持 `'all'`
- **修复**：分别加载 trainval 和 test 两部分，使用 `ConcatDataset` 合并为完整数据集

Bug 3: NameError: name 'model' is not defined

- **现象**：Kaggle 会话重启后，运行评估代码时报变量未定义
- **原因**：会话重启后内存中的所有变量（包括 `model`、`test_loader` 等）丢失
- **修复**：在评估代码开头重新定义模型结构（`weights=None`），并重新运行数据加载 Cell

Bug 4: 中文字体缺失警告

- **现象**：matplotlib 绘图时大量 `UserWarning: Glyph missing from font(s) DejaVu Sans`
- **原因**：Kaggle 环境默认字体不支持中文字符，标题使用中文导致警告
- **修复**：将图表标题改为英文，避免中文字体依赖

参考文献

[1] Oxford-IIIT Pet Dataset: <https://www.robots.ox.ac.uk/~vgg/data/pets/> [2] He, K., et al. "Deep Residual Learning for Image Recognition." CVPR 2016. [3] Szegedy, C., et al. "Rethinking the Inception

Architecture for Computer Vision." CVPR 2016. (Label Smoothing) [4] Zhang, H., et al. "mixup: Beyond Empirical Risk Minimization." ICLR 2018. [5] Selvaraju, R. R., et al. "Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization." ICCV 2017.